

Regimes' Characteristics and Time Series Forecasting

FGV-EESP Masters' Thesis

Ricardo Semião e Castro
Orientador: Marcelo Fernandes

20 mai 2026

Introdução

Objetivo

Pergunta de pesquisa:

- Como modelos de mudança de regimes (RS) desempenham em diferentes processos geradores de dados (DGPs)?
- Como esse desempenho se relaciona com características das distribuições dos regimes?

Objetivo

Pergunta de pesquisa:

- Como modelos de mudança de regimes (RS) desempenham em diferentes processos geradores de dados (DGPs)?
- Como esse desempenho se relaciona com características das distribuições dos regimes?

Mudança de regime: comportamento alterna entre dois ou mais padrões; DGP alterna entre conjuntos de parâmetros.

Objetivo

Pergunta de pesquisa:


- Como modelos de mudança de regimes (RS) desempenham em diferentes processos geradores de dados (DGPs)?
- Como esse desempenho se relaciona com características das distribuições dos regimes?

Mudança de regime: comportamento alterna entre dois ou mais padrões; DGP alterna entre conjuntos de parâmetros.

Comportamento observável nos dados, e útil para modelar não-linearidades, outliers, entre outros.

Exemplos de mudanças de regime


Figura 1: Regimes monetários do BC



Fonte: Lima et al. (2007) “Monetary policy regimes in Brazil” ([link](#)).

Exemplos de mudanças de regime

Figura 2: Vento no noroeste dos EUA



Fonte: Gneiting et al. (2012) “Calibrated Probabilistic Forecasting at the Stateline Wind Energy Center” ([link](#)).


Características dos regimes

Estudar o desempenho desses modelos é importante, e as características (métricas) dos regimes são relevantes.

Características dos regimes

Estudar o desempenho desses modelos é importante, e as características (métricas) dos regimes são relevantes.

Figura 3: Vento no noroeste dos EUA - Distribuições



Fonte: Gneiting et al. (2012).

Resumo da metodologia

- 1 Definir uma estrutura geral dos DGPs, modelos, e métricas dos regimes.
- 2 Gerar séries, previsões, e métricas via simulação de Monte Carlo.
- 3 Estudar os DGPs e performance dos modelos.

Literatura relacionada

Literaturas similares:

- Modelos de estado-espço.
- Modelos de quebras estruturais.

Literatura relacionada

Literaturas similares:

- Modelos de estado-espço.
- Modelos de quebras estruturais.

Literatura de RS:

- Quebras abruptas vs. suaves.
- Processos determinísticos vs. estocásticos.
- *Markov Switching* (MS), *Self-Exciting Threshold* (SET), *Smooth Transition* (ST).
- Modelos 'agnósticos': K-means (KM), Random Forest (RF), Neural Network.

Metodologia

Processos de mudança de regime

Figura 4: A estrutura de um processo de RS

$$\begin{array}{c}
 \underbrace{y_t = \text{sgp}(y_{1:(t-1)}, r_{1:t} ; \Theta_y^s) \cdot r_t^s}_{\text{DGP}} \quad = \quad \underbrace{\text{SGP}}_{\text{functional form}} \quad \& \quad \underbrace{r_t = \text{rgp}(y_{1:(t-1)}, r_{1:(t-1)} ; \Theta_r)}_{\text{regime nature}} \quad \underbrace{\text{RGP}}_{\{\Theta_y^1, \dots, \Theta_y^s\}}
 \end{array}$$

Processos de mudança de regime

Figura 4: A estrutura de um processo de RS

$$\begin{array}{c}
 \underbrace{y_t = \text{sgp}(y_{1:(t-1)}, r_{1:t} ; \Theta_y^s)}_{\text{DGP}} \cdot \underbrace{r_t^s}_{\text{RGP}} = \underbrace{\text{SGP}}_{\text{functional form}} \& \underbrace{\text{RGP}}_{\text{regime nature}} \\
 \underbrace{f_{\text{sgp}}}_{\text{functional form}} \& \underbrace{\{\Theta_y^1, \dots, \Theta_y^s\}}_{\text{regime nature}}
 \end{array}$$

Exemplos:

- RGP: regime 1 se a série passada foi alta, 2 c.c.
- SGP: $AR(1)$ com interceptos diferentes em cada regime.

SGPs consideradas

Forma funcional: $AR(1)$, estacionário, com erros Gaussianos.

SGPs consideradas

Forma funcional: $AR(1)$, estacionário, com erros Gaussianos.

Naturezas dos regimes:

- Mudança em μ : $(\mu^1 = 0, \mu^2 = 0.5)$ e $(\mu^1 = 0, \mu^2 = 1)$.
- Mudança em ρ : $(\rho_1^1 = 0.4, \rho_1^2 = 0.6)$ e $(\rho_1^1 = 0.2, \rho_1^2 = 0.8)$.
- Mudança em σ : $(\sigma^1 = 1, \sigma^2 = 1.5)$ e $(\sigma^1 = 1, \sigma^2 = 2)$.

RGPs e modelos considerados

RGPs:

- Sem RS: sempre no regime 1.
- SET e ST: baseados em y_{t-1} .
- MS: distribuição geométrica.
- Todos com $S = 2$ regimes, uma versão simétrica ($\approx 50-50$), e outra assimétrica ($\approx 75-25$).

RGPs e modelos considerados

RGPs:

- Sem RS: sempre no regime 1.
- SET e ST: baseados em y_{t-1} .
- MS: distribuição geométrica.
- Todos com $S = 2$ regimes, uma versão simétrica ($\approx 50-50$), e outra assimétrica ($\approx 75-25$).

Modelos:

- Recebem y , geram parâmetros, $\hat{r}$ e $\hat{y}$.
- MS, SET, e ST.
- K-means e Random Forest, com 4 lags de y , média, desvio-padrão, e $ACF(1)$ móveis.
- Todos os parâmetros mudam; assume-se 2 regimes.

Métricas dos regimes

Métrica condicional nos regimes: $(y, r) \mapsto \mathbb{R}^S$.

Diferença entre os regimes: $(y, r) \mapsto \mathbb{R}^S \mapsto \mathbb{R}$.

Métricas dos regimes

Métrica condicional nos regimes: $(y, r) \mapsto \mathbb{R}^S$.

Diferença entre os regimes: $(y, r) \mapsto \mathbb{R}^S \mapsto \mathbb{R}$.

Métricas:

- Média, desvio-padrão, e $ACF(1)$.
- Outras métricas: RMSE, R^2 , e ajuste do regime.

Métricas dos regimes

Métrica condicional nos regimes: $(y, r) \mapsto \mathbb{R}^S$.

Diferença entre os regimes: $(y, r) \mapsto \mathbb{R}^S \mapsto \mathbb{R}$.

Métricas:

- Média, desvio-padrão, e $ACF(1)$.
- Outras métricas: RMSE, R^2 , e ajuste do regime.

Questões técnicas:

- Calculadas analiticamente, via (y, r) , ou $(y, \hat{r})$.
- Podem requerer estacionariedade dentro de cada regime.

Simulação de Monte Carlo

Estrutura:

- Para cada DGP e simulação:
 - Gerar erros aleatórios.
 - Gerar (y, r) via $r_1 \rightarrow y_1 \rightarrow r_2 \rightarrow y_2 \rightarrow \dots$
 - Para cada modelo:
 - Obter $\hat{y}$ e $\hat{r}$.
 - Calcular as métricas, gerando um dataset.

Simulação de Monte Carlo

Estrutura:

- Para cada DGP e simulação:
 - Gerar erros aleatórios.
 - Gerar (y, r) via $r_1 \rightarrow y_1 \rightarrow r_2 \rightarrow y_2 \rightarrow \dots$
 - Para cada modelo:
 - Obter $\hat{y}$ e $\hat{r}$.
 - Calcular as métricas, gerando um dataset.

Hiperparâmetros:

- 6 RNs, 7 RGPs e 5 modelos.
- Número de simulações: 500.
- Tamanho da série: 100, +4 descartes e +10 previsões.
- Previsões com janela fixa: $E_{1:T}[y_{T+h} \mid y_{1:(T+h-1)}]$.

Implementação em R (link), paralelizado, reproduzível e expansível.

Diagnósticos

Tabela 1: Problemas de estimação

	Bad obs.	% Bad	% Removed	Obs. left
Full sample	0	0%	0%	126,000
Bad convergence	148	0.1%	0.1%	125,852
NAs in parameters	245	0.2%	0.2%	125,607
Low #obs. in regimes	967	0.8%	0.6%	124,859
Unreasonable parameters	1,803	1.4%	1.3%	123,162
Unreasonable errors	145	0.1%	0%	123,137
Total	3,308	2.6%	2.3%	123,137

Outros: aleatoriedade dos erros; comparação 'verdadeiro vs. estimado' de parâmetros e métricas; independência do índice de simulação.

Distribuições dos regimes


Diferenças entre os regimes

Tabela 2: Separação dos regimes em cada DGP

RGP	RN	$d(\hat{\mu}(.))$		$d(\hat{\rho}_1(.))$		$d(\hat{\sigma}(.))$	
		(0, 0.5)	(0, 1)	(0.1, 0.9)	(0.4, 0.6)	(1, 1.5)	(1, 2)
MS	μ	.85*** (.02)	1.62*** (.03)	.01 (.01)	.01 (.01)	.02 (0)	.02 (.01)
	ρ_1	.03 (.06)	.07 (.3)	.11*** (0)	.38*** (.05)	.12*** (.01)	.53*** (.15)
	σ	.03 (.1)	.01 (.15)	.05** (0)	0 (.03)	.48*** (.06)	.99*** (.14)
SET	μ	1.52*** (.04)	2.29*** (.1)	0 (.01)	.22*** (.05)	.01 (0)	.05*** (.03)
	ρ_1	1.02*** (.05)	1.3*** (.19)	.02 (.03)	.22*** (.02)	.02 (.06)	.22*** (.06)
	σ	1.09*** (.17)	1.24*** (.3)	.13*** (.05)	.14*** (.06)	.49*** (.1)	.98*** (.16)
ST	μ	.64*** (0)	.47*** (.03)	0 (.01)	.08*** (.03)	0 (.01)	.03** (.01)
	ρ_1	.92*** (0)	1.06*** (.07)	.21*** (.02)	.41*** (.05)	.07*** (.01)	.22*** (.02)
	σ	1.15*** (.01)	1.41*** (.07)	.08*** (0)	.05*** (0)	.28*** (.01)	.58*** (.07)

Separação estimada

Figura 5: Diferença verdadeira vs. estimada



Análise de performance

Efeitos fixos dos modelos

Tabela 3: Efeitos fixos dos modelo

	RMSE					
	(1)	(2)	(3)	(4)	(5)	(6)
MS	1.781*** (0.009)	1.308*** (0.005)	1.676*** (0.013)	1.782*** (0.015)	1.569*** (0.015)	1.987*** (0.017)
SET	1.687*** (0.009)	1.322*** (0.005)	1.607*** (0.013)	1.601*** (0.015)	1.529*** (0.015)	1.932*** (0.017)
ST	1.632*** (0.009)	1.313*** (0.005)	1.553*** (0.013)	1.391*** (0.016)	1.611*** (0.015)	1.884*** (0.018)
KM	1.308*** (0.009)	1.132*** (0.005)	1.254*** (0.013)	1.182*** (0.015)	1.180*** (0.015)	1.562*** (0.017)
RF	1.588*** (0.009)	1.214*** (0.005)	1.578*** (0.013)	1.320*** (0.016)	1.508*** (0.015)	1.910*** (0.017)
Strat.	none	asym. RGP	small RN	μ RN	ρ_1 RN	σ RN
Observations	99,944	44,491	50,172	32,357	33,925	33,662
R ²	0.603	0.879	0.591	0.589	0.595	0.639
Adjusted R ²	0.603	0.879	0.591	0.589	0.595	0.639
Residual Std. Error	1.302	0.467	1.280	1.229	1.224	1.398

Note:

*p<0.1; **p<0.05; ***p<0.01

Má-especificação e desempenho

Má especificação da família do RGP diminui o desempenho:

- Efeito base de 0.515 (0.013).
- MS tem efeito ≈ 1.3 vezes maior que SET e ST
- Quando o RGP é sem-RS, o efeito é de 3.531 (0.014).
- RN de σ tem efeito ≈ 1.9 vezes maior do que de μ ou ρ .
- Mudança grande tem efeito ≈ 1.4 vezes maior que uma pequena.
- Nenhum par modelo-RGP tem efeito significativamente diferente de outro, fora com o RGP sem-RS

Modelos e características dos regimes

Tabela 4: Modelos e ‘perfis’ de métricas condicionais verdadeiras

Model	Metric		
	$d(\hat{\mu}(.))$	$d(\hat{\rho}_1(.))$	$d(\hat{\sigma}(.))$
MS	0.01 (0.034)	0.027 (0.344)	-0.012 (0.058)
SET	-0.108*** (0.034)	-0.163 (0.343)	-0.069 (0.058)
ST	-0.168*** (0.034)	0.911*** (0.349)	-0.006 (0.059)
KM	-0.183*** (0.033)	-0.155 (0.34)	-0.128** (0.057)
Observations		100840	
R^2 , Adjusted R^2		0.613, 0.613	
Resid. SE, F stat. p-value		1.317, <0.001	

Porém: com as métricas estimadas, os resultados mudam, e variam entre RNs.

Identificação e desempenho

Tabela 5: RMSE e identificação do fit e r

	RMSE	
	$x = R^2$	$x = BME(r)$
$x \cdot \text{No RS}$	0.749*** (0.009)	-0.914*** (0.012)
$x \cdot \text{MS}$	0.746*** (0.009)	0.497*** (0.021)
$x \cdot \text{SET}$	0.851*** (0.010)	0.329*** (0.018)
$x \cdot \text{ST}$	0.849*** (0.013)	0.347*** (0.012)
$x \cdot \text{KM}$	0.467*** (0.009)	-0.310*** (0.016)
$x \cdot \text{RF}$	1.482*** (0.011)	
Observations	120,850	100,840
R^2	0.288	0.072
Residual Std. Error	1.786	2.039
F Statistic p-value	<0.001	<0.001

Note:

* $p < 0.1$; ** $p < 0.05$; *** $p < 0.01$

Identificação e desempenho

Tabela 6: RMSE e identificação das métricas condicionais

Model	Metric		
	$d(\hat{\mu}(.))$	$d(\hat{\rho}_1(.))$	$d(\hat{\sigma}(.))$
SET	0.737*** (0.02)	0.445*** (0.006)	0.359*** (0.008)
ST	0.36*** (0.007)	0.14*** (0.003)	0.421*** (0.007)
MS	0.228*** (0.005)	0.091*** (0.008)	0.428*** (0.008)
Observations		89065	
R^2 , Adjusted R^2		0.441, 0.441	
Resid. SE, F stat. p-value		1.529, <0.001	

Má-especificação do número de regimes

Tabela 7: Má especificação do número de regimes

	RMSE		
	(1)	(2)	(3)
$\hat{S} < S$	-0.809*** (0.017)		-0.494*** (0.023)
$\hat{S} > S$	0.714*** (0.020)	1.981*** (0.028)	
$\hat{S} > S : d(\hat{\mu}(.))$		-1.927*** (0.029)	
$\hat{S} > S : d(\hat{\rho}_1(.))$		-2.166*** (0.096)	
$\hat{S} > S : d(\hat{\sigma}(.))$		-2.727*** (0.050)	
$\hat{S} < S : d(\hat{\mu}(.))$			0.301*** (0.032)
$\hat{S} < S : d(\hat{\rho}_1(.))$			0.426*** (0.111)
$\hat{S} < S : d(\hat{\sigma}(.))$			0.517*** (0.054)
Constant	1.479*** (0.013)	1.183*** (0.013)	1.580*** (0.017)
Strat.	none	none	no KM
Observations	81,970	81,970	61,128
R ²	0.498	0.519	0.537
Residual Std. Error	0.938	0.918	1.005
F Statistic p-value	<0.001	<0.001	<0.001

Note:

*p<0.1; **p<0.05; ***p<0.01

Conclusão

Conclusão

- Estudei os processos e modelos de RS, através das características das distribuições de seus regimes.
- Defini uma estrutura teórica e de simulações de Monte Carlo, geral e expansível, mas foquei em objetos e exercícios específicos.

Conclusão

- Estudei os processos e modelos de RS, através das características das distribuições de seus regimes.
- Defini uma estrutura teórica e de simulações de Monte Carlo, geral e expansível, mas foquei em objetos e exercícios específicos.

Resultados gerais:

- RGP e RNs interagem significativamente, e as métricas condicionais recuperam algumas relações.
- Modelos erram as métricas condicionais, a depender do modelo e RN; previsões ruins sob r impreciso.
- Subestimar S é menos danoso com regimes similares, e superestimar S é menos danoso com regimes diferentes.

Conclusão

Resultados dos modelos:

- K-means é um bom aproximador: melhor desempenho, consistente em diferentes DGPs, e boas previsões mesmo com r imprecisos.
- Modelos de *threshold* são similares, 'gostam' de mudanças na média.
- ST captura mudanças pequenas, é sensível às séries sem-RS, a mudanças em ρ , e erra a volatilidade condicional.
- MS lida com regimes assimétricos, sofre com má-especificações do RGP e erra métricas condicionais.

Conclusão

Resultados dos modelos:

- K-means é um bom aproximador: melhor desempenho, consistente em diferentes DGPs, e boas previsões mesmo com r imprecisos.
- Modelos de *threshold* são similares, ‘gostam’ de mudanças na média.
- ST captura mudanças pequenas, é sensível às séries sem-RS, a mudanças em ρ , e erra a volatilidade condicional.
- MS lida com regimes assimétricos, sofre com má-especificações do RGP e erra métricas condicionais.

Resultados apresentam fatos úteis para entender os processos e modelos. A análise de modelos $\times$ métricas tem potencial para recomendações práticas.

Limitações

Validade externa: resultados condicionais na população de processos geradores.

Melhoria: adicionar MS-ST, MS+T, outras distribuições para MS, e transformações da variável de *threshold*.

Conjunto de métricas: insuficiente para descrever interações entre todos RGPs e RNs; de difícil estimação pelos modelos.

Melhoria: mais métricas (ex.: outros momentos), mais medidas de dispersão, e versões ponderadas das métricas.

Obrigado!